

Inteligência Artificial Probabilística
Mariana Ramos - 2023217633, Leonor Pereira - 2022212258



UNIVERSIDADE D
COIMBRA

PROJETO FINAL

2025/2026

Introdução

Contexto e Objetivos

Este projeto tem como objetivo principal o desenvolvimento de um sistema de previsão probabilística focado nos resultados de jogos de futebol da liga portuguesa. Através da aplicação de técnicas de modelagem probabilística, pretende-se não apenas prever o desfecho das partidas, mas também quantificar a incerteza associada a essas previsões e avaliar a sua utilidade num contexto real de apostas desportivas.

O trabalho abrange a construção de Redes Bayesianas, a implementação de classificadores probabilísticos com quantificação de incerteza (*Conformal Prediction*) e a aplicação da teoria de utilidade para otimizar a tomada de decisão face às *odds* do mercado.

Seleção de Variáveis

Para a modelagem probabilística inicial, o foco foi colocado em variáveis categóricas (previamente discretizadas) que capturam a dinâmica e o contexto de cada jogo. A variável alvo a prever é o **result**, que assume três estados possíveis: **H** (vitória da equipa da casa), **D** (empate) e **A** (vitória da equipa de fora).

As variáveis explicativas (*features*) selecionadas foram:

- **ht_form** e **at_form**: Representam a forma recente da equipa da casa e da equipa visitante, respetivamente.
- **ht_attack** e **at_attack**: Indicam a capacidade ofensiva recente de ambas as equipas.
- **h2h_dominance**: Captura o domínio histórico em confrontos diretos (*head-to-head*) entre as duas equipas.
- **odds_favorite**: Traduz o favoritismo da partida segundo a perspetiva das casas de apostas.

Preparação e Limpeza dos Dados

Antes da construção dos modelos, o dataset original foi submetido a um processo de limpeza e formatação para garantir a integridade da aprendizagem automática e a compatibilidade com a biblioteca *pgmpy*. Os passos metodológicos foram os seguintes:

(i) **Filtragem de atributos**: Seleção exclusiva das variáveis discretas relevantes e da variável alvo.

(ii) **Tratamento de valores ausentes**: Remoção de todas as observações incompletas (*dropna()*), resultando num conjunto final robusto de 5583 jogos válidos.

(iii) **Conversão de dados**: Transformação de todas as colunas para o tipo *string*, garantindo que os algoritmos interpretem os valores estritamente como categorias independentes.

(iv) **Divisão estratificada**: Separação em dados de treino (80%, 4466 jogos) e de teste (20%, 1117 jogos). Foi aplicada amostragem estratificada com base na variável *result* para preservar a proporção real e o desequilíbrio natural das classes em ambos os conjuntos.

PARTE 1: Redes Bayesianas

Nesta primeira fase do projeto, o objetivo consistiu em modelar a incerteza associada aos resultados de jogos de futebol através de Redes Bayesianas. O dataset utilizado é composto por 5583 jogos, contendo informações históricas discretizadas sobre a forma das equipas, capacidade atacante, histórico de confrontos diretos (*h2h*) e o favoritismo ditado pelas casas de apostas (*odds*).

1. Construção de Estruturas e Avaliação de Desempenho

Foram avaliadas três abordagens distintas para a construção da Rede Bayesiana:

1. **Knowledge Engineering (Modelo Manual):** Estrutura desenhada com base no conhecimento do domínio, onde todas as variáveis explicativas apontam diretamente para a variável alvo (*result*).
2. **Aprendizagem Computacional (Modelo Automático):** Estrutura aprendida a partir dos dados de treino utilizando o algoritmo *Hill Climbing* otimizado pelo critério BIC (*Bayesian Information Criterion*).
3. **Naive Bayes (Baseline):** Modelo simplificado que assume independência condicional entre todas as *features* dado o resultado.




Fig. 1




Fig. 2




Fig. 3

Os três modelos apresentaram desempenhos globais semelhantes. O **Modelo Automático (55.24%)** e o **Naive Bayes (55.15%)** registaram as melhores *accuracies* globais. Contudo, a análise detalhada dos resultados e do gráfico de *Recall* por Classe (Fig. 3) revela um pormenor crítico: o Modelo Automático atingiu este valor sacrificando totalmente a previsão da classe minoritária D (empates), apresentando métricas nulas (*Recall* e *Precision* de 0.00). Em claro contraste, o **Modelo Manual**, apesar de apresentar uma *accuracy* ligeiramente inferior (**51.66%**), destacou-se por tentar ativamente prever esta classe de

maior incerteza, identificando corretamente 41 empates (comportamento apenas acompanhado pelo Naive Bayes, com 31 acertos).

Para compreender esta diferença de comportamento entre os modelos, é necessário observar o desequilíbrio natural dos dados e o peso das variáveis explicativas. A análise inicial (Fig. 2) demonstra que as vitórias da casa (H) constituem a classe maioritária (~45%), seguidas das vitórias da equipa de fora (A) e, por fim, dos empates (D). Para além disso, como evidenciado nos gráficos da Fig. 4 e Fig. 5, o favoritismo nas *odds* e a boa forma da equipa da casa fornecem sinais estatísticos muito fortes e claros para a previsão da classe H. O empate, por outro lado, representa um evento de elevada entropia, cujos padrões são ambíguos nas variáveis discretizadas.

Perante este cenário de desequilíbrio e incerteza, o algoritmo de aprendizagem de estrutura (*Hill Climbing*), utilizado no Modelo Automático, adotou uma estratégia estritamente conservadora. Para maximizar a *accuracy* global, o algoritmo focou-se em prever exclusivamente as classes com sinais estatísticos mais óbvios (H e A), optando por ignorar o ruído gerado pela dificuldade de prever empates.




Fig. 4




Fig. 5

2. Análise de Independências Condicionais (D-Separation)

Para garantir que as redes construídas representam fielmente as dependências reais do domínio, recorreu-se ao conceito de D-separação.

No Modelo Manual (**Estrutura Collider**), os testes provaram que variáveis como *ht_form* e *at_form*, ou *ht_attack* e *at_attack*, são independentes quando não condicionadas a nenhuma evidência, tornando-se, no entanto, dependentes quando condicionadas à variável alvo *result*. Esta topologia forma uma estrutura de *collider* (ou *V-structure*), o que desencadeia o fenómeno de "*explaining away*". Ou seja, as causas subjacentes a um jogo são independentes à priori; contudo, se soubermos o desfecho do jogo, o conhecimento de uma causa altera a probabilidade das outras. Este comportamento confirma que a estrutura manual modela corretamente a realidade causal do desporto.

No Modelo Automático (**Estrutura Fork**), a topologia aprendida foi bastante diferente, tendo o algoritmo definido *h2h_dominance* e *odds_favorite* como os "nós centrais" que afetam o *result* e as restantes covariáveis. Consequentemente, variáveis como *ht_form* e *at_form* são dependentes à priori, mas tornam-se independentes quando condicionadas em

[*'h2h_dominance'*, *'odds_favorite'*]. Trata-se de uma estrutura em *Fork*, o que indica que o algoritmo considerou que toda a informação útil para prever o resultado já está perfeitamente contida nas *odds* e no histórico de confrontos diretos, desvalorizando a forma e o ataque para o papel de variáveis apenas com poder explicativo indireto.

3. Aprendizagem de Parâmetros

Após a definição da estrutura, estimaram-se as Tabelas de Probabilidade Condicional (CPTs) do Modelo Manual recorrendo a dois métodos: *Maximum Likelihood Estimation* (MLE) e Estimação Bayesiana (com prior *BDeu*).




Fig. 6

A avaliação de desempenho (Fig. 6) revelou que ambos os métodos atingiram exatamente a mesma *accuracy* no conjunto de teste (**51.66%**). Esta equivalência justifica-se pela dimensão robusta dos dados de treino (4466 jogos), cujo elevado volume empírico acaba por se sobrepor à influência do *prior* Bayesiano na esmagadora maioria das inferências.

Contudo, a inspeção às CPTs expôs a principal falha do MLE: a vulnerabilidade à esparsidade dos dados. Perante combinações muito específicas que nunca ocorreram no treino (ex: uma equipa estatisticamente fraca, mas que seja considerada favorita), o MLE falha ao atribuir probabilidades nulas (**0%**). É nestes cenários anómalos que a Estimação Bayesiana demonstra superioridade. Ao utilizar um tamanho de amostra equivalente, este método atua como regularizador para suavizar as distribuições, impedindo probabilidades a zero e garantindo a robustez do modelo face à incerteza do futebol.

Na prática, o impacto desta limitação técnica do MLE é residual para este projeto. Sendo o *dataset* suficientemente extenso e cobrindo largamente os padrões normais do desporto, as combinações em que o MLE falha são casos extremos e estatisticamente raros.

4. Inferências Probabilísticas e Análise de Cenários

Para testar a validade prática do modelo na captura da semântica do domínio, efetuaram-se *queries* probabilísticas na rede manual através do algoritmo de *Variable Elimination*:

- **Favoritismo e Forma (Q1):** Quando a equipa da casa está em boa forma (*ht_form*: good) e é favorita nas apostas (*odds_favorite*: home), a probabilidade da vitória em

casa dispara para 48.98%. Isto valida os sinais visuais encontrados na análise exploratória de dados.

- **Cenário de Equilíbrio (Q2):** Perante formas médias de ambas as equipas, o modelo prevê um jogo dividido (H: 36.27% / A: 34.10%), refletindo a ausência de um sinal preditivo forte de desequilíbrio e mantendo apenas uma ligeira vantagem natural de jogar em casa.
- **Inferência MAP (Q3):** A classe mais provável perante um histórico de domínio da casa (*h2h_dominance: home_dominant*) foi corretamente identificada como H, comprovando o peso dos confrontos históricos na dinâmica dos resultados em Portugal.
- **Ataque vs Defesa (Q4):** Quando uma equipa ataca bem contra uma que ataca mal, a probabilidade sobe a favor do melhor ataque (H: 36.55%), mas de forma muito discreta. Isto traduz o princípio futebolístico de que um bom ataque não garante, isoladamente, a vitória.
- **A Equipa da Casa em Desvantagem Teórica (Q5):** Exigindo ao modelo que preveja o resultado de uma equipa da casa em má forma que enfrenta um adversário que é favorito nas casas de apostas, a rede atribui 41.74% à vitória da equipa de fora (A) contra apenas 27.74% da vitória em casa. O modelo prova, assim, ter capacidade para superar a "vantagem de jogar em casa" quando os indicadores factuais apontam o cenário oposto.
- **Equilíbrio Total (Q6):** Expandindo a Q2, ao fixar tanto a forma como o ataque de ambas as equipas no nível médio (average), a probabilidade de empate fixa-se nos 25.31%, mantendo-se inferior às probabilidades de vitória. Isto reflete as próprias características do *dataset*: mesmo num cenário onde as equipas aparentam forças teoricamente idênticas, o empate é um evento de menor probabilidade estatística.

Conclusão Parte 1

Em síntese, as inferências confirmam que o modelo capturou coerentemente a complexidade do futebol. A rede não assume cegamente a vantagem da casa, conseguindo cruzar variáveis, como a forma e as *odds*, para inverter o favoritismo quando os dados o exigem (Q5). Paralelamente, o modelo respeita a distribuição real do *dataset*, mantendo o empate como o cenário menos provável mesmo perante equipas estatisticamente equilibradas (Q6).

PARTE 2: Classificação Probabilística, Calibração e Otimização

Nesta segunda fase do projeto, aprofundou-se a modelação probabilística dos resultados dos jogos recorrendo a implementações *standard* de *Machine Learning* (via *scikit-learn*), focando na quantificação da incerteza, na fiabilidade das probabilidades geradas e na otimização paramétrica.

1. Implementação do Classificador Naive Bayes

Como ponto de partida para esta fase, treinou-se um classificador probabilístico Naive Bayes (*CategoricalNB*), mantendo a divisão dos dados em 80% para treino e 20% para teste, estratificada pela variável alvo. O objetivo foi estabelecer uma baseline robusta e comparar o seu comportamento com as Redes Bayesianas da Parte 1.

O modelo atingiu uma *accuracy* global de **55.15%**. Importa notar que a classe maioritária (H) representa aproximadamente **44.1%** do conjunto de teste (493 em 1117 jogos). Assim, um classificador trivial que previsse sempre a vitória da casa atingiria cerca de 44.1% de *accuracy*. Os modelos desenvolvidos conseguem melhorar este valor em cerca de 11 pontos percentuais, demonstrando que existe efetivamente sinal preditivo nos dados, ainda que limitado.

A análise detalhada das métricas de avaliação revelou uma assimetria evidente no poder preditivo:

- **Classe H (Vitória da Casa):** Apresentou o melhor desempenho, com um *recall* de 80% e *precision* de 58%. O modelo identifica facilmente os sinais de vitória da casa, embora à custa de alguns falsos positivos.
- **Classe A (Vitória Visitante):** Mostrou um comportamento intermédio e equilibrado, com *recall* de 55% e *precision* de 54%.
- **Classe D (Empate):** Confirmou-se como o evento mais complexo de modelar. Com um *recall* de apenas 11% e *precision* de 38%, o modelo demonstrou enorme relutância em prever empates, evidenciando o enviesamento típico de classificadores perante classes minoritárias e de elevada entropia.

Estes resultados sugerem que as variáveis disponíveis possuem capacidade preditiva limitada para este problema. Contudo, a principal vantagem desta abordagem probabilística é a capacidade de extrair um grau de confiança contínuo (probabilidades) em vez de uma decisão binária, o que se revela fundamental para cenários práticos de tomada de decisão.

2. Quantificação de Incerteza com Conformal Prediction

Para lidar com a elevada imprevisibilidade dos empates e a incerteza geral das previsões, aplicou-se a metodologia de *Conformal Prediction*. Em vez de forçar o modelo a devolver uma única classe (que frequentemente está errada perante elevada incerteza), esta técnica produz "conjuntos de previsão" (*prediction sets*) com garantias matemáticas de cobertura empírica.

Para o efeito, o conjunto de treino foi subdividido para criar um set de calibração exclusivo. Definiu-se uma taxa de erro marginal $\alpha = 0.1$, visando garantir que a classe verdadeira estivesse contida no conjunto de previsão em pelo menos **90%** dos casos.

Resultados da Calibração:

- O quantil de conformidade estabeleceu-se em **0.9251**.
- A cobertura empírica no conjunto de teste atingiu **91.58%**, cumprindo com sucesso a garantia teórica estipulada (>90%).

A análise da distribuição do tamanho dos conjuntos reflete de forma transparente a dificuldade do problema:

- **Tamanho 1 (19.0% dos jogos):** O modelo apresenta elevada certeza e isola apenas um resultado plausível.
- **Tamanho 2 (27.2% dos jogos):** Incerteza moderada, onde o modelo reduz as opções a dois desfechos prováveis.

- **Tamanho 3 (53.8% dos jogos):** Incerteza máxima. Em mais de metade dos jogos, o modelo não teve confiança suficiente para descartar qualquer desfecho sem violar a garantia de 90% de cobertura.

Esta abordagem prova o seu valor analítico perante a ambiguidade intrínseca do futebol. Em contextos como apostas desportivas, saber atempadamente quando um jogo é excessivamente ambíguo (tamanho 3) é tão útil quanto prever corretamente um resultado óbvio.

3. Avaliação da Calibração do Modelo

Para além da precisão (*accuracy*), avaliou-se até que ponto as probabilidades devolvidas pelo Naive Bayes refletem a frequência real dos eventos no mundo real, um conceito conhecido como calibração.

As métricas globais registaram um Log Loss de **1.0704** e um Brier Score médio de **0.2011**. Um Log Loss acima de 1 sugere que, em alguns casos, o modelo mostra-se demasiado confiante em previsões incorretas.




Fig. 7

A análise visual através de *Reliability Diagrams* (Fig. 7) expôs discrepâncias notórias entre as classes:

- **Classe A:** Apresentou sobreconfiança em probabilidades baixas. Nos jogos em que o modelo julgava a vitória da equipa de fora muito improvável (0 a 50%), o evento ocorreu com uma frequência superior à esperada.
- **Classe D:** Apresenta um comportamento distinto das restantes. O modelo raramente atribui probabilidades elevadas ao empate, mantendo as previsões concentradas abaixo de ~45%. Isto indica forte incerteza estrutural relativamente a esta classe. Apesar do baixo *recall* observado anteriormente, a calibração da classe D não é necessariamente a pior. Pelo contrário, o Brier Score mais baixo (0.1869) sugere que o modelo evita previsões excessivamente confiantes para empates, mantendo uma postura conservadora. O principal problema da classe D não é sobreconfiança, mas sim incapacidade discriminativa, o modelo não consegue separar adequadamente jogos propensos a empate dos restantes cenários.
- **Classe H:** Foi a classe mais bem calibrada. A sua curva seguiu proximamente a diagonal ideal, o que significa que quando o modelo atribui 80% ou 90% de probabilidade a uma vitória de casa, essa equipa vence de facto em proporções muito idênticas no mundo real.

4. Otimização Bayesiana com Regressão Logística

Após a avaliação do classificador Naive Bayes, colocou-se a hipótese de a *accuracy* ter estagnado na casa dos 55% devido à simplicidade do algoritmo, que assume independência condicional entre as variáveis e possui um espaço de hiperparâmetros muito limitado. Para testar esta hipótese, introduziu-se um modelo de Regressão Logística Multinomial. Este modelo linear foi escolhido por permitir capturar relações mais complexas entre as variáveis e por possuir um espaço contínuo de hiperparâmetros muito mais rico, tornando-o no candidato ideal para a aplicação de técnicas avançadas de pesquisa.

Recorreu-se à Bayesian Optimization (via “*BayesSearchCV*”) para a exploração do espaço de hiperparâmetros. Face a métodos tradicionais, como pesquisas exaustivas (*Grid Search*) ou puramente aleatórias (*Random Search*), esta abordagem destaca-se por ser significativamente mais inteligente e eficiente.

O espaço de pesquisa foi definido em torno de três hiperparâmetros fundamentais:

- **Força de Regularização (C):** Pesquisada numa escala log-uniforme (entre 0.001 e 100). A regularização serve para evitar que o modelo decore os dados de treino (*overfitting*). Valores mais baixos de C implicam uma penalização mais forte.
- **Solver:** O algoritmo responsável por encontrar os pesos ideais do modelo. Foram testados o “*lbfgs*” e o “*saga*”, ambos adequados para problemas multinomiais.
- **Max_iter:** O limite de iterações permitidas para o *solver* convergir (500, 1000 ou 2000).

O processo executou 30 avaliações distintas. Para garantir a robustez e evitar que o modelo se adaptasse a uma divisão específica dos dados, cada avaliação utilizou *5-fold cross-validation*, ou seja, o modelo foi treinado e testado 5 vezes por cada configuração testada.

Análise de Convergência e Melhores Hiperparâmetros

A análise do gráfico de convergência (Fig. 8) demonstra a eficiência da Otimização Bayesiana.




Fig. 8

O algoritmo encontrou melhorias significativas logo numa fase inicial (por volta da 10ª iteração) e atingiu o ponto ótimo na **14ª iteração**, estabilizando a partir daí. Isto comprova

que o limite de 30 iterações foi perfeitamente adequado. A configuração ideal encontrada pelo algoritmo foi: **C** - 0.0033, **solver** - saga e **max_iter** - 2000.

O dado mais revelador desta configuração é o valor extremamente baixo de C (forte regularização). Este resultado sugere estatisticamente que o sinal preditivo nos dados é bastante fraco e ruidoso. Para não cair em *overfitting*, o modelo necessitou de comprimir fortemente os coeficientes das variáveis, indicando que tentar extrair padrões complexos deste dataset leva facilmente a falsas conclusões.

Desempenho e o "Custo" da Accuracy

Avaliado no conjunto de teste, a Regressão Logística otimizada atingiu uma *accuracy* global de **55.42%**, uma melhoria muito marginal face aos **55.15%** obtidos pelo Naive Bayes não otimizado.

No entanto, após a análise dos valores do *Classification Report*, verificámos que esta ligeira subida teve um custo comportamental drástico: o modelo otimizado ignorou por completo a classe D (empates). Os dados demonstram que, para um universo de 281 jogos que efetivamente terminaram em empate (*support*), o modelo registou *precision*, *recall* e *f1-score* de 0.00. Na prática, isto significa que o algoritmo não conseguiu (ou não tentou) prever corretamente um único empate.

Em contrapartida, o modelo compensou essa ausência sobrecarregando as previsões nas outras duas classes. Isto é particularmente evidente na classe H, onde o modelo atingiu um *recall* excecionalmente alto de **90%**, acompanhado por um *recall* aceitável de **52%** para a classe A.

Este comportamento é uma consequência matemática direta da otimização num cenário de alta incerteza. Como a fronteira de decisão para os empates é demasiado ambígua, o modelo percebeu que apostar na classe D resultava frequentemente em erro e prejudicava a métrica principal. Assim, para maximizar estritamente a *accuracy* global que lhe foi exigida como critério de sucesso, o modelo optou por ignorar os empates e distribuir os palpites entre as classes estatisticamente mais seguras (H e A). A prova definitiva deste desequilíbrio é o baixo valor de *macro avg f1-score* (**0.41**), uma métrica que, ao contrário da *accuracy*, penaliza fortemente o modelo por esta falha estrutural na identificação de uma das três classes.

Conclusão Parte 2

Os resultados obtidos com a Otimização Bayesiana são a prova empírica final que corrobora as descobertas da Parte 1. O facto de uma Regressão Logística altamente otimizada necessitar de uma regularização extrema e acabar por sacrificar os empates apenas para maximizar ligeiramente a precisão global demonstra que o teto de previsibilidade deste problema reside, inequivocamente, em torno dos 55%.

A limitação não está na capacidade dos algoritmos, mas sim na natureza caótica do desporto e na informação contida nas variáveis disponíveis. Assim, conclui-se que o verdadeiro valor prático destes modelos aplicados ao futebol não reside na procura irrealista de uma *accuracy* perfeita, mas sim na sua capacidade de quantificar a incerteza de forma honesta, isolando cenários de alto risco, um objetivo atingido com sucesso nesta fase através da técnica de Conformal Prediction.

PARTE 3: Teoria de Utilidade e Tomada de Decisão

1. Avaliação de Utilidade e Divergência Face às Odds

Para avaliar se o modelo treinado consegue detetar ineficiências no mercado, foi necessário colocar as suas probabilidades lado a lado com as probabilidades do mercado. As *odds* fornecidas pelas casas de apostas foram convertidas em probabilidades implícitas (através do inverso da *odd*, normalizado para remover a margem de lucro da casa de apostas).

Metodologia de Divergência

Calculou-se a diferença absoluta (divergência média) entre as probabilidades geradas pelo modelo Naive Bayes e as probabilidades implícitas das *odds* para cada jogo. O objetivo era identificar as instâncias onde o modelo discordava radicalmente do consenso do mercado.




Fig. 9

A distribuição desta divergência (Fig. 9) revelou que a maioria dos jogos apresenta uma divergência baixa a moderada. Definiu-se um limiar rigoroso no percentil 75 (**P75 = 0.162**) para isolar os 25% de jogos com alta divergência, ou seja, os casos onde o modelo e as casas de apostas têm opiniões estatisticamente opostas.

Análise de Desempenho

A questão central da Teoria de Utilidade neste contexto consiste em determinar quem tem razão quando o modelo discorda significativamente das *odds*.




Fig. 10

Através da análise comparativa do gráfico (Fig. 10), observamos que nos jogos de alta divergência, o modelo atingiu uma *accuracy* de **~56.4%**, enquanto que as *odds* alcançaram

um valor bastante semelhante (~55.8%). Em paralelo, nos jogos de baixa divergência, ambos os sistemas convergiram para uma precisão em torno dos 55%.

Conclui-se, a eficácia do modelo para superar o mercado, quando considerado isoladamente, é inexistente. Estes resultados provam que a divergência do modelo face às *odds* não representa uma verdadeira vantagem competitiva (*edge*), tratando-se apenas de uma variação estatística normal. Isto demonstra que as casas de apostas constituem uma *baseline* altamente otimizada que o modelo, limitado aos atributos disponíveis, não consegue superar de forma sistemática.

Expected Value (EV) e Calibração Probabilística

Na tentativa de explorar a utilidade dos modelos para identificar oportunidades de aposta, calculou-se o *Expected Value* (EV) para cada previsão. A análise indicou que o modelo atribui um EV positivo a uma enorme proporção dos jogos (97.85%).

No entanto, a baixa *accuracy* observada especificamente nestes jogos (~47.8%) demonstra que este EV positivo não corresponde a uma verdadeira vantagem económica. Na realidade, reflete as limitações de calibração probabilística do modelo documentadas na Parte 2: a tendência do algoritmo para estar sobreconfiante e subestimar a probabilidade de empates gera falsas expectativas de valor. Num mercado eficiente, uma percentagem tão irrealista de "value bets" reforça que o modelo não deve ser utilizado cegamente contra o mercado.

2. Quantificação de Incerteza e Estratégia de *Reject Option*

Face à impossibilidade de superar as *odds* de forma cega, a abordagem de decisão foi refinada. Implementou-se uma estratégia de *Reject Option*, onde o modelo pode rejeitar previsões de elevada incerteza. Em vez de forçar uma previsão em todos os jogos, o modelo quantifica a sua própria incerteza e recusa-se a prever jogos demasiado ambíguos, deferindo a decisão para o consenso do mercado (as *odds*).

Medição de incerteza (Entropia)

A incerteza de cada previsão foi medida através da Entropia de Shannon. Num problema de 3 classes (H, D, A), a entropia máxima ocorre quando o modelo atribui exatamente 33.3% a cada desfecho, resultando num valor de ~1.0986. Quanto mais próximo deste valor, maior a confusão do modelo.

Impacto do Limiar de Rejeição (*Threshold*)

Testaram-se vários limiares de entropia. Se a entropia de um jogo for inferior ao limiar, o modelo aceita e prevê o jogo, se for superior, o modelo rejeita e assume a previsão da *odd* mais provável. A análise iterativa do gráfico (Fig. 11) demonstrou o valor real do sistema:

- **Alta Confiança / Elevada Rejeição (*Threshold* 0.50):** Quando o sistema é configurado para ser extremamente conservador (aceitando apenas entropias muito baixas), ele rejeita mais de 72% dos jogos. No entanto, nos 27.5% dos jogos que aceita prever, a sua *accuracy* dispara para uns impressionantes 76.6%.

Isto demonstra que o modelo tem uma excelente capacidade de autodiagnóstico, ele sabe exatamente quando tem razão.

- **Baixa Confiança / Pouca Rejeição (*Threshold* ~0.75):** À medida que se aumenta a tolerância à entropia, o modelo abrange mais jogos na sua rede (a linha laranja pontilhada cresce aceleradamente), mas o seu desempenho preditivo dilui-se de forma proporcional, caindo gradualmente em direção aos 55% da *baseline*.




Fig. 11

Maximização do Desempenho Preditivo

O objetivo final desta estratégia era determinar se a combinação entre as previsões ultra-confiantes do modelo e o deferimento para as *odds* nos restantes jogos (cenários de alta incerteza) geraria um sistema híbrido superior. Observando os dados, a *accuracy* global das *odds* em todo o conjunto de teste é de **55.5%**. A precisão da estratégia combinada, independentemente do limiar de entropia escolhido, oscila de forma muito estreita entre os **55.1%** e os **55.8%**. O facto de a precisão combinada não descolar da precisão base das *odds* valida, uma vez mais, a ineficiência de tentar bater o mercado globalmente.

Contudo, a estratégia de *Reject Option* revela-se a descoberta mais valiosa do projeto no âmbito da Teoria da Decisão. A utilidade do algoritmo não reside na predição cega de todos os jogos do calendário, mas na sua conversão num filtro de alta precisão. Ao calibrar a entropia para limiares em torno de **0.50** a **0.60**, o decisor consegue isolar cerca de um terço do campeonato com uma precisão empírica observada entre **72%** e **76%**, abdicando conscientemente de apostar no caos estrutural que caracteriza os restantes jogos.

Limitações do Estudo

Apesar dos resultados obtidos, o estudo apresenta várias limitações importantes que devem ser consideradas:

- O *dataset* contém apenas variáveis agregadas e discretizadas, não incorporando fatores contextuais dinâmicos altamente relevantes como lesões, fadiga acumulada, condições meteorológicas, motivação competitiva ou alterações táticas de última hora.
- O problema de classificação apresenta uma elevada aleatoriedade intrínseca, característica comum na modelação de eventos desportivos de baixo resultado (*low-scoring games*).
- As *odds* utilizadas já incorporam a inteligência coletiva do mercado financeiro e os modelos quantitativos altamente sofisticados operados pelas casas de apostas, servindo como uma *baseline* quase inultrapassável.

- O modelo foi avaliado essencialmente em métricas de classificação, não tendo sido simulada uma estratégia financeira real que contemplasse *Return on Investment* (ROI) acumulado, alocação fracionária ou gestão de banca.

Conclusão Final

Ao longo deste projeto, percorreu-se o espectro completo da modelação probabilística. A **Parte 1** estabeleceu, através de Redes Bayesianas, que a estrutura condicional do futebol é ruidosa e que as variáveis disponíveis possuem um teto preditivo de aproximadamente 55%. A **Parte 2** confirmou essa limitação ao aplicar algoritmos de *Machine Learning* e técnicas de calibração, evidenciando a dificuldade estrutural em modelar eventos de elevada entropia, como o empate, e o valor do autodiagnóstico probabilístico.

Finalmente, a **Parte 3** aplicou estes modelos a um contexto de Teoria de Decisão. Os resultados sugerem fortemente que o mercado de apostas desportivas apresenta um elevado grau de eficiência informacional, tornando extremamente difícil superar de forma consistente as probabilidades implícitas das *odds* utilizando apenas histórico estatístico. No entanto, demonstrou-se que o verdadeiro valor da Inteligência Artificial neste domínio não reside na ilusão da predição perfeita, mas sim na **previsão consciente da incerteza** (*uncertainty-aware prediction*). Ao permitir que o modelo aja como um filtro rigoroso (*Reject Option*), é possível gerir o risco e tomar decisões com elevadas margens de precisão, aceitando a imprevisibilidade intrínseca do desporto como parte fundamental do processo analítico.